

DETECÇÃO DE ANOMALIAS EM TRANSAÇÕES FINANCEIRAS

Relatório Técnico Completo

Gerado em 18/06/2026 12:07

Melhor Modelo: Voting Classifier (Auto-Melhorado)

F1-Score: 87.8%

Prejuízo Evitado: R\$ 50,839.91

Total de Modelos: 10

1. RESUMO EXECUTIVO

O projeto alcançou desempenho EXCEPCIONAL com F1-Score de 87.8%. O modelo campeão foi Voting Classifier (Auto-Melhorado).

Métricas do Melhor Modelo

- Detecta 84.7% das fraudes reais
- 91.2% dos alertas são fraudes reais
- ROC-AUC: 98.2%
- Falsos positivos: 40

Análise de Risco

Risco Financeiro: MÉDIO | Recomendação: IMPLEMENTAR COM MONITORAMENTO

[OK] Precision excelente (91.2%): Apenas 40 falsos positivos. Impacto operacional mínimo.

2. RANKING DE MODELOS

Modelo	Recall	Precision	F1	ROC-AUC
Voting Classifier (Auto-Melhor)	84.7%	91.2%	87.8%	98.2%
Voting Classifier	85.7%	76.4%	80.8%	98.6%
Random Forest	84.7%	76.9%	80.6%	98.1%
XGBoost	87.8%	68.3%	76.8%	98.4%
LightGBM	84.7%	67.5%	75.1%	97.8%
Stacking Ensemble	87.8%	57.7%	69.6%	98.6%
Voting Classifier (Threshold D	15.3%	60.0%	24.4%	83.5%
Voting Classifier (Sistema Híb	15.3%	60.0%	24.4%	83.5%
Autoencoder	26.5%	8.3%	12.6%	92.5%
Isolation Forest	1.0%	0.3%	0.5%	82.2%

Distribuição de Performance

- Excelentes (F1 >= 80%): 3 modelo(s)

3. IMPACTO FINANCEIRO

Com 284,807 transações e 492 fraudes, o modelo evita R\$ 50,839.91.

PREJUÍZO EVITADO
R\$ 50,839.91

PREJUÍZO RESIDUAL
R\$ 9,288.06

Indicadores

- Fraudes detectadas: 416 de 492 (84.7%)
- Falsos positivos: 40
- Eficiência: 84.6%
- Valor médio fraude: R\$ 122.21

4. ANÁLISE DE PADRÕES DE FRAUDE

Padrão de Valores

- Valor médio de fraude: R\$ 122.21
- Valor médio de normal: R\$ 88.29
- Fraudes são 1.4x maiores em média
- Valor mediano de fraude: R\$ 9.25
- Valor mediano de normal: R\$ 22.00
- Percentil 95 das fraudes: R\$ 640.90
- Percentil 99 das fraudes: R\$ 1357.43

Insights Principais

[WARNING] Valores de fraude e normal são similares (1.4x) - valor sozinho não é bom indicador isolado.

5. RECOMENDAÇÕES ESTRATÉGICAS

Curto Prazo (Próximos 30 dias)

1. Implementar modelo Voting Classifier (Auto-Melhorado) em ambiente de homologação
2. Monitorar estabilidade do threshold atual (precision: 91.2%)
3. Investigar 76 fraudes não detectadas para identificar padrões

Médio Prazo (Próximos 90 dias)

1. Implementar ensemble dos top 3 modelos para reduzir gap de performance.
2. Coletar feedback dos analistas sobre falsos positivos.
3. Implementar monitoramento de drift (dados atuais: 284k+ transações).

Longo Prazo (Próximos 6 meses)

1. Escalar sistema para processamento em tempo real (eficiência atual: 84.6%).
2. Desenvolver sistema de auto-retreinamento baseado em feedback.
3. Expandir para detecção de novos tipos de fraude.

6. ANÁLISE DETALHADA POR MODELO

Esta seção apresenta a análise detalhada de cada modelo treinado, incluindo matrizes de confusão e curvas ROC.

Modelos Treinados

1. Voting Classifier (Auto-Melhorado) - F1: 87.8%, Recall: 84.7%, Precision: 91.2%
2. Voting Classifier - F1: 80.8%, Recall: 85.7%, Precision: 76.4%
3. Random Forest - F1: 80.6%, Recall: 84.7%, Precision: 76.9%
4. XGBoost - F1: 76.8%, Recall: 87.8%, Precision: 68.3%
5. LightGBM - F1: 75.1%, Recall: 84.7%, Precision: 67.5%

As imagens das matrizes de confusão e curvas ROC estão disponíveis na pasta results/figures/.

Arquivos gerados:

- cm_*.png (Matrizes de Confusão)
- roc_*.png (Curvas ROC)
- pr_*.png (Curvas Precision-Recall)

7. IMPACTO FINANCEIRO - TODOS OS MODELOS

Análise comparativa do impacto financeiro de todos os modelos treinados.

Tabela Comparativa

Modelo	F1	Recall	Prec	Fraudes	Prejuízo	FPs	ROI
XGBoost	76.8%	87.8%	68.3%	431	R\$52,673	200	417%
Stacking Ensemble	69.6%	87.8%	57.7%	431	R\$52,673	315	411%
Voting Classifier	80.8%	85.7%	76.4%	421	R\$51,451	130	408%
Random Forest	80.6%	84.7%	76.9%	416	R\$50,840	125	402%
LightGBM	75.1%	84.7%	67.5%	416	R\$50,840	200	398%
Voting Classifier (Auto-M	87.8%	84.7%	91.2%	416	R\$50,840	40	406%
Autoencoder	12.6%	26.5%	8.3%	130	R\$15,887	1440	-13%
Voting Classifier (Thresh	24.4%	15.3%	60.0%	75	R\$9,166	50	-11%
Voting Classifier (Sistem	24.4%	15.3%	60.0%	75	R\$9,166	50	-11%
Isolation Forest	0.5%	1.0%	0.3%	5	R\$611	1455	-167%

Métricas de Negócio Avançadas

- Custo por Transação: R\$ 0.0035
- Taxa de Aprovação: 99.78%
- Valor Médio/Alerta: R\$ 83.41
- Break-even: 82 fraudes
- Índice Eficiência: 68.3%
- Payback Period: 2.3 meses

8. SOBRE O PROJETO

Objetivo

Sistema completo de detecção de fraudes em cartões de crédito utilizando técnicas avançadas de Machine Learning e Deep Learning.

Tecnologias Utilizadas

Linguagem:

- Python 3.12

Manipulação e Análise de Dados:

- NumPy (computação numérica e arrays)
- Pandas (manipulação e análise de dados tabulares)

Machine Learning:

- Scikit-learn (Random Forest, Voting Classifier, Stacking Ensemble, Isolation Forest, SMOTE, métricas, pipelines)
- XGBoost (Gradient Boosting otimizado)
- LightGBM (Gradient Boosting de alta performance)
- imbalanced-learn (balanceamento de classes com SMOTE)

Deep Learning:

- TensorFlow (Autoencoder para detecção de anomalias)

Explicabilidade (Explainable AI):

- SHAP (SHapley Additive exPlanations - dependence plots, interaction matrix, waterfall)

Visualização de Dados:

- Matplotlib (gráficos estáticos e dashboards)
- Seaborn (heatmaps e visualizações estatísticas)
- Plotly (gráficos interativos para web)

Interface e API:

- Streamlit (interface web interativa)
- FastAPI (API REST para microserviço)
- Pydantic (validação de dados na API)
- Uvicorn (servidor ASGI para FastAPI)

Relatórios e Serialização:

- FPDF2 (geração de relatórios PDF dinâmicos)
- Joblib (serialização e persistência de modelos)

Estatística:

- SciPy (teste Kolmogorov-Smirnov para detecção de drift)

Resultados Principais

- 10 modelos implementados (8 supervisionados, 2 não-supervisionados)
- Voting Classifier (Auto-Melhorado) como melhor modelo (F1-Score: 87.8%)
- 84.7% das fraudes detectadas
- R\$ 50,839.91 em prejuízo evitado

Técnicas Avançadas Implementadas

- Engenharia de Features (70+ variáveis: temporais, frequência, valor, distância temporal, interação, polinomiais, risco composto)
- SMOTE para balanceamento de classes
- Sklearn Pipelines (prevenção de data leakage)
- Random Forest, XGBoost, LightGBM
- Voting Classifier (ensemble de 3 modelos)
- Stacking Ensemble (meta-aprendizado com Logistic Regression)
- Isolation Forest (detecção não-supervisionada)
- Autoencoder (Deep Learning para anomalias)
- Threshold Dinâmico baseado em custo financeiro
- Sistema Híbrido (Regras de Negócio + ML)
- Auto-aprendizado (Self-Improvement System)
- Model Drift Detection (KS Test + PSI)
- SHAP Avançado (dependence plots, interaction matrix, waterfall plots)
- Visualizações interativas (Plotly)
- Relatórios PDF dinâmicos (FPDF2)
- Dashboard profissional (Matplotlib)
- Interface web (Streamlit)
- API REST (FastAPI)

9. CONCLUSÃO

O projeto demonstrou detecção de fraudes com 84.6% de eficiência, com melhor modelo atingindo F1-Score de 87.8%.

Resumo Final

416 fraudes detectadas de 492.

R\$ 50,839.91 em prejuízos evitados.

10 modelos treinados e comparados.

18 técnicas profissionais aplicadas com sucesso.

Próximos Passos

1. Implementar em ambiente de produção com monitoramento contínuo
2. Coletar feedback dos analistas para refinamento do modelo
3. Expandir para detecção de novos tipos de fraude
4. Desenvolver sistema de auto-retreinamento baseado em dados de produção